LAPORAN PRAKTIKUM

IMPLEMENTASI COMMUNITY DETECTION METODE LEIDEN DAN SISTEM REKOMENDASI COLLABORATIVE FILTERING PADA DATASET MOVIELENS MENGGUNAKAN NEO4J

Mata Kuliah: Graf Sains Data
S1 Sains Data, Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Negeri Surabaya

Kelompok 10

No	Nama	NIM
1	Shafira Nabila Noer Poerwanto	23031554011
2	Muhammad Rif'at Syarief	23031554053
3	Novia Djoend Lestari	23031554220

Instance / Database: gsd / movielens
Tanggal pengerjaan di Neo4j: 20 Oktober 2026

1. Pendahuluan

Laporan ini menjelaskan apa yang dikerjakan kelompok kami di Neo4j menggunakan data film MovieLens. Data ini berisi film, pengguna, dan rating (nilai 0,5 sampai 5) yang diberikan pengguna untuk film. Neo4j menyimpan data sebagai graf, yaitu kumpulan titik (node) yang dihubungkan oleh garis (relasi). Dengan graf, kita bisa melihat siapa menilai film apa, lalu mencari pola dari hubungan itu.

1.1 Tujuan

1. Memasukkan data MovieLens ke Neo4j sebagai graf pengguna, film, dan genre.
2. Mengelompokkan node dengan metode Leiden (community detection).
3. Membuat rekomendasi film dengan collaborative filtering.

1.2 Dataset

Dataset terdiri dari dua file CSV. Jumlahnya 610 pengguna, 9.742 film, 20 genre, dan 100.836 rating.

File	Isi	Menjadi di Neo4j
movies.csv	ID film, judul, genre	Node Movie, node Genre, relasi IN_GENRE
ratings.csv	ID pengguna, ID film, rating, waktu	Node User, relasi RATED

1.3 Alat

- Neo4j, database `movielens` pada instance `gsd`.
- Plugin Graph Data Science (GDS) untuk algoritma Leiden.
- Neo4j Browser untuk menjalankan query dan mengambil screenshot.

Semua angka di laporan ini disalin dari hasil eksekusi di Neo4j (log dan screenshot). Hal yang belum pasti kami kumpulkan di Bagian 9. Semua query ada di folder `cypher/`, satu file untuk setiap langkah.

2. Konsep Singkat

2.1 Graf

Graf terdiri dari **node** (titik) dan **relasi** (garis antartitik). Pada data ini, ada tiga jenis node: pengguna (User), film (Movie), dan genre (Genre). Ada dua jenis relasi: RATED (pengguna memberi rating ke film) dan IN_GENRE (film masuk ke genre tertentu).

2.2 Community detection dan Leiden

Bayangkan kantin sekolah. Tanpa bertanya, kita bisa menebak siapa satu kelompok dengan siapa, cukup dari siapa yang sering duduk bersama. Community detection melakukan hal yang

sama pada graf: node yang banyak saling terhubung dimasukkan ke satu kelompok (komunitas).

Leiden bekerja dalam tiga langkah yang diulang: (1) memindahkan node ke kelompok yang paling cocok, (2) memperbaiki kelompok agar anggotanya benar-benar saling terhubung, (3) menggabungkan kelompok lalu mengulang. Hasil akhirnya dinilai dengan **modularity (Q)**. Q makin tinggi berarti pembagian kelompok makin jelas. Sebagai aturan kasar, nilai di atas sekitar 0,3 dianggap menunjukkan kelompok yang cukup jelas.

2.3 Collaborative filtering

Collaborative filtering memberi rekomendasi dari selera orang lain. Jika kamu dan temanmu sama-sama menyukai beberapa film yang sama, film lain yang disukai temanmu kemungkinan juga kamu sukai.

3. Persiapan Database

Sebelum data dimasukkan, kami membuat tiga aturan ID unik (constraint). Aturan ini memastikan setiap film, pengguna, dan genre hanya tercatat satu kali. Neo4j juga otomatis membuat indeks dari aturan ini, sehingga pencarian data lebih cepat.

```
CREATE CONSTRAINT FOR (m:Movie) REQUIRE m.movieId IS UNIQUE;
CREATE CONSTRAINT FOR (u:User) REQUIRE u.userId IS UNIQUE;
CREATE CONSTRAINT FOR (g:Genre) REQUIRE g.name IS UNIQUE;
```

Ketiga aturan berhasil dibuat dalam 644 ms (Movie), 146 ms (User), dan 130 ms (Genre).

4. Memasukkan Data

Data dimasukkan dalam tiga langkah: film dan genre, lalu pengguna, lalu rating. Urutannya penting karena relasi rating baru bisa dibuat jika pengguna dan film sudah ada.

4.1 Film dan genre

Satu film bisa punya beberapa genre yang ditulis sekaligus, misalnya "Action|Comedy". Fungsi `split()` memecahnya menjadi genre satu per satu. Setiap genre dibuat menjadi node Genre dan dihubungkan ke filmnya dengan relasi IN_GENRE.

```
LOAD CSV WITH HEADERS FROM 'file:///movies.csv' AS row
MERGE (m:Movie {movieId: toInteger(row.movieId)})
SET m.title = row.title
WITH m, split(row.genres, '|') AS genres
FOREACH (genreName IN genres |
  MERGE (g:Genre {name: genreName})
  MERGE (m)-[:IN_GENRE]->(g)
);
```

Hasil: selesai dalam 7.872 ms, membuat 9.762 node baru (9.742 film dan 20 genre), 22.084 relasi IN_GENRE, dan 19.504 properti.

4.2 Pengguna

```
LOAD CSV WITH HEADERS FROM 'file:///ratings.csv' AS row
WITH DISTINCT row.userId AS userId
MERGE (:User {userId: toInteger(userId)});
```

Hasil: 610 node User dalam 1.097 ms.

4.3 Rating

Ada 100.836 rating yang diubah menjadi relasi RATED. Agar memori tidak penuh, data disimpan sedikit demi sedikit, 10.000 baris setiap kali. Setiap relasi menyimpan nilai rating dan waktu pemberian rating.

```
LOAD CSV WITH HEADERS FROM 'file:///ratings.csv' AS row
CALL (row) {
  MATCH (u:User {userId: toInteger(row.userId)})
  MATCH (m:Movie {movieId: toInteger(row.movieId)})
  CREATE (u)-[r:RATED {rating: toFloat(row.rating), timestamp:
toInteger(row.timestamp)}]->(m)
} IN TRANSACTIONS OF 10000 ROWS;
```

Hasil: selesai dalam 10.713 ms dan membuat 100.836 relasi RATED.

4.4 Hasil akhir

Setelah ketiga langkah selesai, panel Database information di Neo4j Browser menunjukkan 10.372 node dan 122.920 relasi.

Jenis	Jumlah
Node User	610
Node Movie	9.742
Node Genre	20 (dihitung dari log, lihat catatan)
Total node	10.372
Relasi RATED	100.836
Relasi IN_GENRE	22.084
Total relasi	122.920

Catatan: jumlah genre dihitung dari log, yaitu 9.762 node baru dikurangi 9.742 film. Sebagai pengecekan, 9.742 x 2 (movieId dan title) + 20 (name genre) = 19.504 properti, sama dengan log. Hasil ini sebaiknya dicocokkan dengan query `MATCH (g:Genre) RETURN count(g).`

5. Proyeksi Graf GDS

Algoritma GDS tidak bekerja langsung pada data di disk. GDS membuat salinan graf di memori (RAM) yang disebut proyeksi, supaya perhitungan lebih cepat. Proyeksi ini bukan database baru. Kami memasukkan node User dan Movie beserta relasi RATED, dan menganggap relasinya tidak berarah (UNDIRECTED), artinya bisa dibaca dari pengguna ke film maupun sebaliknya. Node Genre tidak ikut diproyeksikan.

```
CALL gds.graph.project(
  'movielensGraph',
  ['User', 'Movie'],
  {
    RATED: {
      orientation: 'UNDIRECTED',
      properties: ['rating']
    }
  }
);
```

Keluaran	Nilai
Nama proyeksi	movielensGraph
Jumlah node (nodeCount)	10.352 (610 User + 9.742 Movie)
Jumlah relasi (relationshipCount)	201.672
Lama pembuatan	1.955 ms

Jumlah relasi 201.672 adalah dua kali jumlah rating (100.836 x 2), karena relasi tidak berarah dihitung dari dua sisi. Jumlah node 10.352 sama dengan 10.372 dikurangi 20 node Genre.

6. Hasil Community Detection Leiden

6.1 Mode stats

Mode stats hanya menghitung hasil tanpa menyimpannya. **Modularity (Q)** menunjukkan seberapa jelas graf terbagi menjadi kelompok.

```
CALL gds.leiden.stats('movielensGraph')
YIELD communityCount, modularity
RETURN communityCount AS Total_Komunitas_Leiden,
       round(modularity, 4) AS Skor_Modularitas_Q;
```

Hasil: **24 komunitas** dengan **Q = 0,2776**, dihitung dalam 907 ms.

6.2 Mode write

Mode write menyimpan nomor komunitas ke setiap node sebagai properti `leidenCommunity`. Dengan begitu nomor komunitas bisa dipakai di query biasa, termasuk untuk visualisasi pada Bagian 7.

```
CALL gds.leiden.write('movielensGraph', { writeProperty: 'leidenCommunity' });
```

Keluaran	Nilai
Waktu total (Neo4j Browser)	3.593 ms
Rincian waktu	persiapan 17 ms, perhitungan 929 ms, pengolahan akhir 120 ms, penulisan 1.847 ms
Pengaturan	theta 0,01; gamma 1,0; tolerance 0,0001; maxLevels 10; concurrency 4
Selesai stabil (didConverge)	TRUE, setelah 2 tahap (ranLevels = 2)
Node yang diberi nomor komunitas	10.352
Jumlah komunitas	25
Modularity (Q)	0,2769 (tahap 1: 0,2524; tahap 2: 0,2769)

Keluaran	Nilai
Ukuran komunitas	terkecil 1, median 1, persentil 75 = 38, persentil 90 = 1.995, terbesar 3.266, rata-rata 414,08 node

6.3 Perbedaan hasil stats dan write

Pada graf yang sama, mode stats memberi 24 komunitas dengan Q = 0,2776, sedangkan mode write memberi 25 komunitas dengan Q = 0,2769. Selisih Q sebesar 0,0007 bukan karena pembulatan. Dugaan kami, penyebabnya adalah unsur acak pada perhitungan paralel (concurrency 4). Dugaan ini belum diuji. Untuk memastikannya, Leiden perlu dijalankan ulang dengan `randomSeed` yang tetap.

6.4 Arti nilai modularity

Nilai Q sekitar 0,28 berada sedikit di bawah batas kasar 0,3. Artinya pembagian komunitas ada, tetapi belum sangat tegas. Nilai ini perlu dibaca hati-hati karena graf yang dianalisis berisi pengguna dan film sekaligus.

6.5 Ukuran komunitas

Tabel berikut berisi sepuluh komunitas terbesar berdasarkan jumlah film. Kolom contoh film berisi empat judul pertama di setiap komunitas.

No	ID komunitas	Jumlah film	Contoh film
1	4	3.094	Kicking and Screaming (1995), Before Sunrise (1995), Jason's Lyric (1994), Underground (1995)
2	2	2.789	The City of Lost Children (1995), Shanghai Triad (1995), When Night Is Falling (1995), Lamerica (1994)
3	25	1.923	Four Rooms (1995), Cry the Beloved Country (1995), Fair Game (1995), Hate (La Haine) (1995)
4	0	1.036	Toy Story (1995), Jumanji (1995), Grumpier Old Men (1995), Waiting to Exhale (1995)
5	65	481	It Takes Two (1995), The Scout (1994), Gone Fishin' (1997), The Mark of Zorro (1940)
6	48	294	Barbarella (1968), Funny Face (1957), To Be or Not to Be (1942), Swing Kids (1993)
7	10	107	Persuasion (1995), Jane Eyre (1996), Around the World in 80 Days (1956), The Sword in the Stone (1963)
8	37	1	For All Mankind (1989)
9	9	1	Niagara (1953)
10	64	1	The Innocents (1961)

Tujuh komunitas teratas berisi 107 sampai 3.094 film. Tiga komunitas terakhir hanya berisi satu film. Pada hasil mode write, median ukuran komunitas adalah 1, artinya separuh atau lebih komunitas hanya berisi satu node. Dugaan kami, itu film yang belum pernah dinilai sehingga

tidak terhubung ke siapa pun. Dugaan ini bisa dicek dengan query pada file `cypher/04_analisis_komunitas.cypher`.

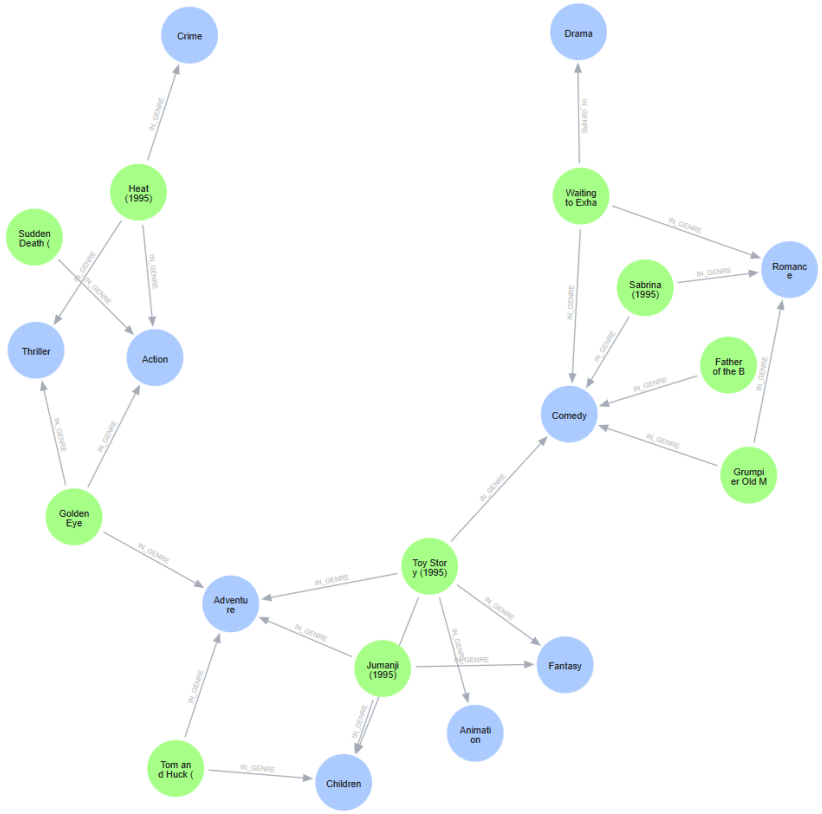
Empat contoh film pertama di setiap komunitas belum cukup untuk menyimpulkan tema komunitasnya. Tabel ini berasal dari hasil mode stream, sedangkan nomor komunitas yang tersimpan di database berasal dari mode write. Karena Leiden memakai unsur acak, nomor komunitas pada tabel bisa berbeda dari nomor yang tersimpan.

7. Visualisasi Graf

Bagian ini berisi enam gambar dari Neo4j Browser. Tujuannya memastikan data sudah masuk dengan benar dan melihat bentuk grafnya. Setiap query memakai LIMIT, jadi gambar hanya contoh sebagian data. Angka di dalam lingkaran pengguna adalah nomor komunitas Leiden mereka (`leidenCommunity`). Query lengkapnya ada di `cypher/05_visualisasi.cypher`.

7.1 Film dan genre

Query `MATCH p=()-[:IN_GENRE]->() RETURN p LIMIT 25;` menampilkan 20 node (10 film berwarna hijau dan 10 genre berwarna biru) dengan 25 relasi IN_GENRE. Genre seperti Adventure, Action, dan Comedy terhubung ke banyak film. Satu film juga bisa terhubung ke beberapa genre, misalnya Toy Story ke Adventure, Animation, Comedy, dan Fantasy.



Gambar 1. Hubungan film dan genre (query IN_GENRE, LIMIT 25).

7.2 Pengguna dan film yang dinilai

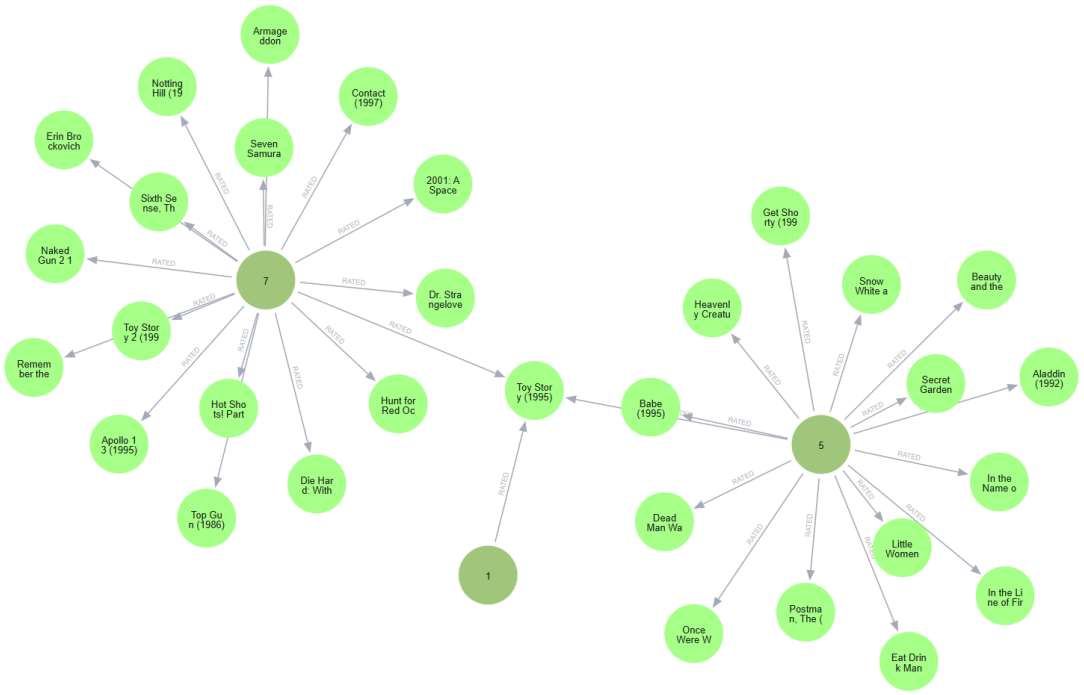
Query `MATCH p=()-[:RATED]->() RETURN p LIMIT 25;` menampilkan 26 node (1 pengguna dan 25 film) dengan 25 relasi RATED. Bentuknya seperti bintang: satu pengguna di tengah, terhubung ke 25 film. Ini menunjukkan bahwa satu pengguna memberi rating ke banyak film.



Gambar 2. Satu pengguna dan film-film yang ia beri rating (query RATED, LIMIT 25).

7.3 Jalur rekomendasi

Query pada `cypher/05_visualisasi.cypher` (5.3) menelusuri jalur dari pengguna 1 ke film yang mungkin ia sukai: pengguna 1, film yang sama-sama dinilai, pengguna lain yang mirip, lalu film yang disukai pengguna lain itu. Hasilnya 34 node (31 film dan 3 pengguna) dengan 33 relasi RATED, dalam 4.990 ms. Pada gambar, jalur dari pengguna 1 melewati Toy Story (1995) ke dua pengguna lain, lalu ke film-film yang mereka sukai, misalnya Apollo 13, Die Hard, Seven Samurai, dan Aladdin. Karena LIMIT 30, gambar hanya memuat sebagian jalur. Film peringkat teratas pada Bagian 8 tidak harus muncul di gambar ini.

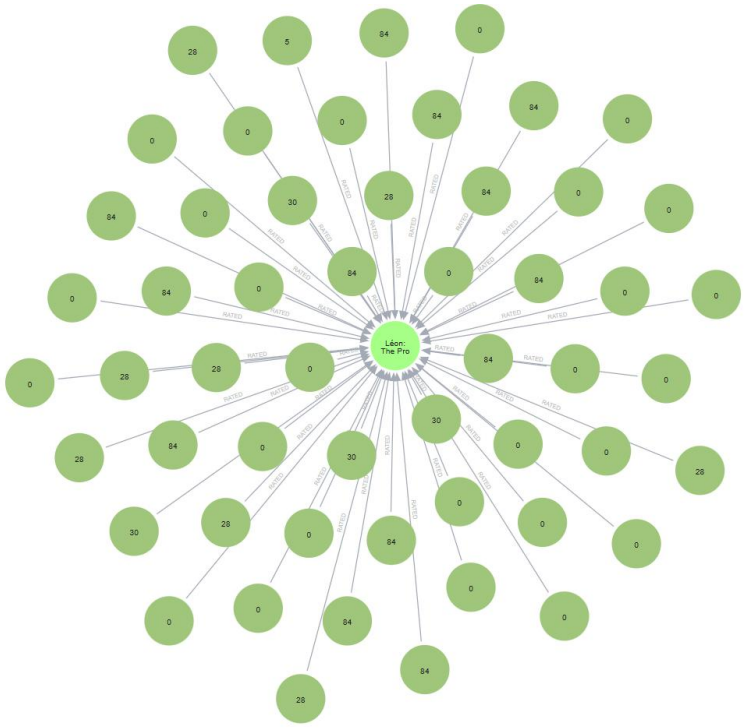


Gambar 3. Jalur rekomendasi dari pengguna 1 ke film yang disarankan.

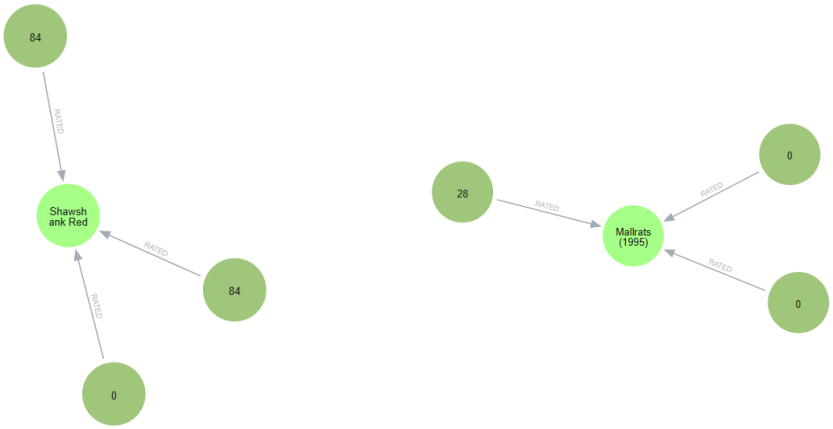
7.4 Film dari komunitas Leiden

Query 5.4 mengambil film dari komunitas Leiden 0, 2, dan 6 beserta pengguna yang memberi rating 4,5 ke atas. Hasilnya 63 node (3 film dan 60 pengguna) dengan 60 relasi RATED. Tiga film yang tampil adalah Léon: The Professional, The Shawshank Redemption, dan Mallrats. Léon dikelilingi paling banyak pengguna, sedangkan dua film lainnya masing-masing tiga pengguna.

Angka di lingkaran pengguna beragam (0, 5, 28, 30, 84). Artinya, pengguna yang menyukai satu film tidak selalu berada di satu komunitas. Gambar ini hanya contoh kecil sehingga belum cukup untuk membuktikan seberapa terpisah komunitasnya.



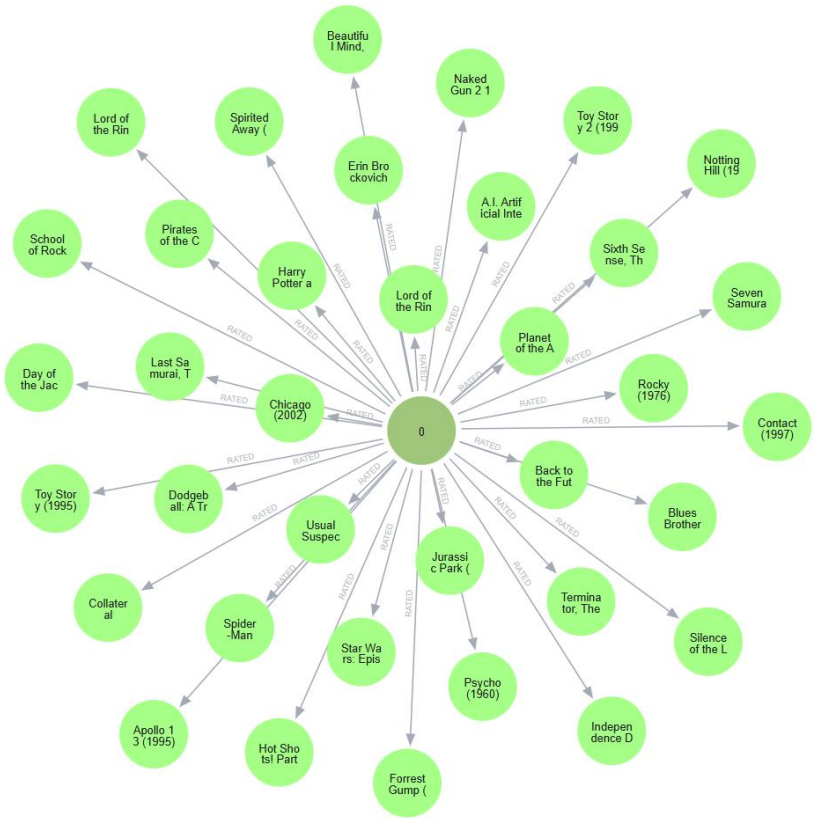
Gambar 4a. Léon: The Professional dan pengguna yang memberi rating 4,5 ke atas.



Gambar 4b dan 4c. The Shawshank Redemption (kiri) dan Mallrats (kanan).

7.5 Film lain yang disukai penonton Toy Story

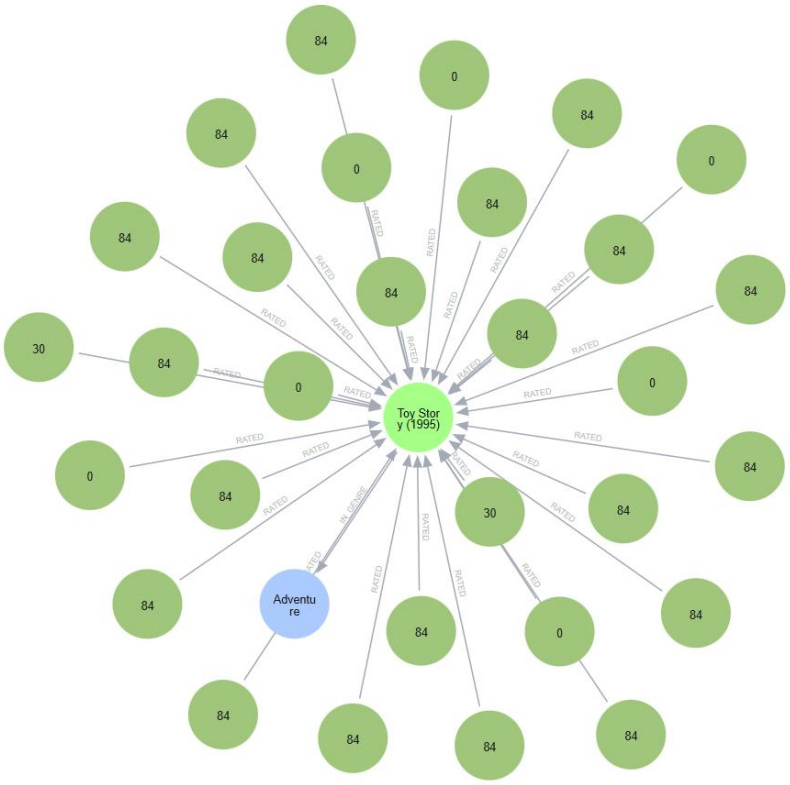
Query 5.5 mencari film lain yang juga diberi rating 4,5 ke atas oleh pengguna yang menyukai Toy Story (1995). Hasilnya 37 node (1 pengguna dan 36 film) dengan 36 relasi RATED. Gambar ini menunjukkan bahwa dua film bisa dianggap berhubungan jika disukai oleh orang yang sama. Ide inilah yang dipakai pada sistem rekomendasi.



Gambar 5. Film lain yang disukai pengguna yang menyukai Toy Story.

7.6 Toy Story dan pengguna yang memberi rating 5,0

Query 5.6 menampilkan Toy Story, genrenya, dan pengguna yang memberinya rating 5,0. Hasilnya 32 node dan 30 relasi. Pada gambar hanya terlihat genre Adventure karena LIMIT 30 memotong baris hasil, padahal Toy Story punya beberapa genre (lihat Gambar 1). Di sekeliling Toy Story tampak banyak pengguna dengan nomor komunitas 84, 0, dan 30.



Gambar 6. Toy Story, genre Adventure, dan pengguna yang memberi rating 5,0.

8. Sistem Rekomendasi Collaborative Filtering

Rekomendasi dibuat untuk pengguna 1 (`userId = 1`) dengan mencari pengguna lain yang seleranya mirip, lalu menyarankan film yang mereka sukai. Ada empat aturan:

1. Pengguna lain dianggap mirip jika selisih ratingnya pada film yang sama paling banyak 1,0.
2. Pengguna mirip harus punya minimal 3 film yang sama dengan pengguna 1, supaya kemiripannya bukan kebetulan.
3. Film yang disarankan harus diberi rating 4,0 ke atas oleh pengguna mirip.
4. Film yang sudah dinilai pengguna 1 tidak disarankan lagi.

```
MATCH (target:User {userId: 1})-[r1:RATED]->(common:Movie)<-[r2:RATED]-
(peer:User)
WHERE target <> peer
  AND abs(r1.rating - r2.rating) <= 1.0
WITH target, peer, count(DISTINCT common) AS film_bersama
WHERE film_bersama >= 3

MATCH (peer)-[r3:RATED]->(rec:Movie)
WHERE NOT (target)-[:RATED]->(rec)
  AND r3.rating >= 4.0
RETURN rec.title AS Rekomendasi_Film,
       count(DISTINCT peer) AS Jumlah_User_Serupa,
       round(avg(r3.rating), 2) AS Prediksi_Rating
ORDER BY Jumlah_User_Serupa DESC, Prediksi_Rating DESC
LIMIT 10;
```

Query ini selesai dalam 4.605 ms (satu kali percobaan). Hasilnya:

No	Film	Pengguna serupa	Rata-rata rating
1	The Shawshank Redemption (1994)	266	4,65
2	The Godfather (1972)	153	4,64
3	Terminator 2: Judgment Day (1991)	149	4,49
4	The Lord of the Rings: The Fellowship of the Ring (2001)	140	4,57
5	The Lord of the Rings: The Return of the King (2003)	134	4,51
6	Apollo 13 (1995)	126	4,40
7	The Lord of the Rings: The Two Towers (2002)	125	4,51
8	The Sixth Sense (1999)	124	4,40
9	Memento (2000)	121	4,51
10	The Lion King (1994)	114	4,42

Kolom "Pengguna serupa" menunjukkan berapa pengguna mirip yang menyukai film itu. Kolom "Rata-rata rating" (di query bernama Prediksi_Rating) adalah rata-rata rating dari mereka. Karena hanya rating 4,0 ke atas yang dihitung, nilainya pasti di atas 4,0. Jadi angka ini bukan tebakan nilai dari pengguna 1, melainkan tanda seberapa disukai film itu oleh pengguna yang mirip.

Hasil cenderung berisi film populer, karena film yang banyak ditonton lebih sering muncul. Rekomendasi ini memakai rating secara langsung, tidak memakai komunitas Leiden. Menggabungkan keduanya, misalnya hanya mencari pengguna mirip di komunitas yang sama, bisa menjadi pengembangan berikutnya.

9. Keterbatasan dan Hal yang Perlu Dicek

- **Data kecil.** Hanya 610 pengguna dan 9.742 film. Hasilnya belum tentu sama pada data yang jauh lebih besar.
- **Hasil Leiden berubah-ubah.** Mode stats memberi 24 komunitas (Q = 0,2776) dan mode write memberi 25 komunitas (Q = 0,2769). Nomor komunitas juga bisa berbeda antar-run. Perlu dijalankan ulang dengan `randomSeed` tetap.
- **Modularity sedang.** Q sekitar 0,28 menunjukkan pembagian komunitas yang belum sangat tegas.
- **Banyak komunitas berisi satu node.** Dugaan kami itu film tanpa rating. Belum dicek.
- **Jumlah genre (20) dihitung dari log.** Perlu dicocokkan dengan query `MATCH (g:Genre) RETURN count(g).`
- **Visualisasi hanya contoh.** Setiap gambar memakai LIMIT, jadi tidak mewakili seluruh graf. Gambar 6 hanya menampilkan satu genre.
- **Rekomendasi condong ke film populer** dan waktunya (sekitar 4,6 detik) berasal dari satu kali percobaan. Akurasi rekomendasi belum dievaluasi.

- **Manfaat praktis belum diuji.** Misalnya untuk menyusun daftar film bertema atau menentukan target promosi.

10. Kesimpulan

1. Data MovieLens berhasil dimasukkan ke Neo4j sebagai graf dengan 610 pengguna, 9.742 film, 20 genre, 100.836 rating, dan 22.084 relasi genre.
2. Leiden menemukan 24 komunitas pada mode stats (Q = 0,2776) dan 25 komunitas pada mode write (Q = 0,2769). Pembagian komunitas ada, tetapi belum sangat tegas.
3. Collaborative filtering memberi 10 rekomendasi film untuk pengguna 1, dengan The Shawshank Redemption di urutan pertama (266 pengguna serupa).
4. Keterbatasan utama adalah data kecil, hasil Leiden yang berubah antar-run, dan rekomendasi yang condong ke film populer.

Lampiran A. Daftar File Cypher

File	Isi
01_import_data.cypher	Constraint, impor film, genre, pengguna, dan rating, serta pengecekan jumlah data
02_proyeksi_graf.cypher	Proyeksi graf GDS movielensGraph
03_leiden.cypher	Leiden mode stats dan mode write
04_analisis_komunitas.cypher	Jumlah komunitas, ukuran komunitas, dan film di dalamnya (ditulis ulang, perlu dicocokkan)
05_visualisasi.cypher	Enam query visualisasi untuk screenshot
06_rekomendasi.cypher	Rekomendasi film untuk pengguna 1